

Reporte de Capa: Workload

Término clave: Ghost Work

Diagnóstico Observado

El operador ve jobs de entrenamiento de ML que esperan 4-6 horas en cola mientras GPUs A100 reservadas permanecen idle al 95%. El scheduler asigna recursos por proyecto en vez de por demanda real. Workloads batch que corren en horarios de pico eléctrico cuando podrían correr en valle. Reservas de GPUs con ventanas de 8 horas donde el trabajo efectivo dura 90 minutos. Colas de inferencia que se acumulan detrás de jobs de entrenamiento de baja prioridad que nunca se preemptan.

Impacto Económico: \$3.2M (anuales por cada cluster de 500 GPUs con patrones de ghost work)

- GPUs reservadas ociosas (compute): 53% (\$1.70M)
- Energía de GPUs en idle: 14.0000000000000002% (\$0.45M)
- Costo de oportunidad de workloads no ejecutados: 21% (\$0.67M)
- Penalizaciones por SLA incumplidos: 12% (\$0.38M)

Causa Raíz

Políticas de scheduling estáticas sin feedback loop con la telemetría del facility. Asignación por reservación sin mecanismos de release automático. Desconexión entre el orquestador de workloads (Kubernetes, Slurm, custom schedulers) y la capa de energía/cooling: el scheduler no sabe que correr un job a las 3 AM reduce el costo de cooling un 22% porque la temperatura ambiente es menor. Los equipos de ML reservan recursos "por si acaso" y no los liberan.